中文文档提取测试：文字层

第一段：这是一段用于测试中文文字层提取的文本，包含全角标点：，。！？；：“”‘’。这一页还要验证段落合并、行尾换行和常见汉字覆盖率。

第二段：混排 English words、数字 12345、百分比 98.7%，以及括号（测试）和破折号——结束。

第三段：常见汉字覆盖测试——的一是不了在人有我他这个们中来上大为和国地到以说时要就出会可也对生能而子那得于着下自之年过发后作里用道行所然家种事成方多经去法学如都同现当没动面起看定天分还进好小部其些主样理心她本前开但因只从想实日军者意无力它与长把机十民第公此已工使情明性知全三又关点正业外将两高间由问很最重并物手应战向头文体政美相见被利什二等产或新己制身果加西斯月话合回特代内信表化老给世位次度门任常先海通教儿原东声提立及比员解水名真论处走义各入几口认条平系气题活尔更别打女变四神总何电数安少报才结反受目太量再感建务做接必场件计管期市直德资命山金指克许统区保至队形社便空决治展马科司五基眼书非则听白却界达光放强即像难且权思王象完设式色路记南品住告类求据程北边死张该交规万取拉格望觉术领共确传师观清今切院让识候带导争运笑飞风步改收根干造言联持组每济车亲极林服快办议往元英士证近失转夫令准布始怎呢存

第四段：这一段的长度用于填满第二栏，让双栏阅读顺序可以被观察。如果提取器把两栏交错输出，这一段和上一段就会混在一起。中文没有空格，所以词级指标会掩盖这种错误；必须用字符级 CER。